Construção de corpus multi-camada de comentários bíblicos patrísticos

Iury Anderson Fernandes Coelho[1]

[1]MBA Data Science and Analytics – USP/ESALQ

Orientador: [Nome do Orientador]

2026

Resumo

Este trabalho descreve a construção de um corpus estruturado de comentários bíblicos patrísticos contendo 31.218 arquivos de versículos e 55.925 comentários individuais, cobrindo 66 livros bíblicos e mais de 100 autores do período AD 100–1700. O corpus foi construído através de um pipeline de quatro etapas: extração híbrida via *web scraping* (Firecrawl + BeautifulSoup), limpeza automática de codificação utilizando a biblioteca `ftfy`, tradução automática para português brasileiro via GPT-4o-mini e enriquecimento estruturado por inteligência artificial. A etapa de limpeza corrigiu 14.906 problemas de codificação e reduziu o tamanho do corpus em 33%, de 195 MB para 131 MB, sem perda de conteúdo. O dataset está disponível publicamente sob licença CC BY 4.0.

Palavras-chave: corpus patrístico, pipeline de dados, limpeza de texto, processamento de linguagem natural, *web scraping*

1 Considerações iniciais

Comentários bíblicos patrísticos são textos exegéticos produzidos pelos Pais da Igreja entre os séculos II e XVIII. Esses textos representam mais de 1.600 anos de tradição interpretativa e constituem uma fonte histórica de valor significativo para estudos teológicos, linguísticos e computacionais. Autores como Agostinho de Hipona (AD 430), João Crisóstomo (AD 407), Beda (AD 735) e Jerônimo (AD 420) produziram comentários versículo a versículo que permanecem referência na tradição cristã.

Apesar da importância desses textos, sua disponibilidade em formato estruturado para processamento computacional é limitada. Plataformas como o CatenaBible.com disponibilizam comentários em formato web, porém sem estruturação adequada para análises de processamento de linguagem natural [NLP] ou recuperação de informação [IR].

O objetivo deste trabalho é apresentar a construção de um corpus multi-camada de comentários patrísticos, desde a extração automática até o enriquecimento por inteligência artificial, com ênfase na rastreabilidade, reprodutibilidade e qualidade dos dados.

2 Material e métodos

2.1 Fonte de dados

Os comentários foram extraídos do CatenaBible.com, uma plataforma que disponibiliza textos patrísticos organizados versículo a versículo. Os textos originais são de domínio público, produzidos entre AD 100 e AD 1700. A fonte cobre o cânon completo (66 livros), incluindo livros deuterocanônicos.

2.2 Arquitetura do pipeline

O pipeline é composto por quatro camadas numeradas sequencialmente. Cada camada é produzida por um único script, e cada script mapeia exatamente uma transição entre camadas (Figura 1).

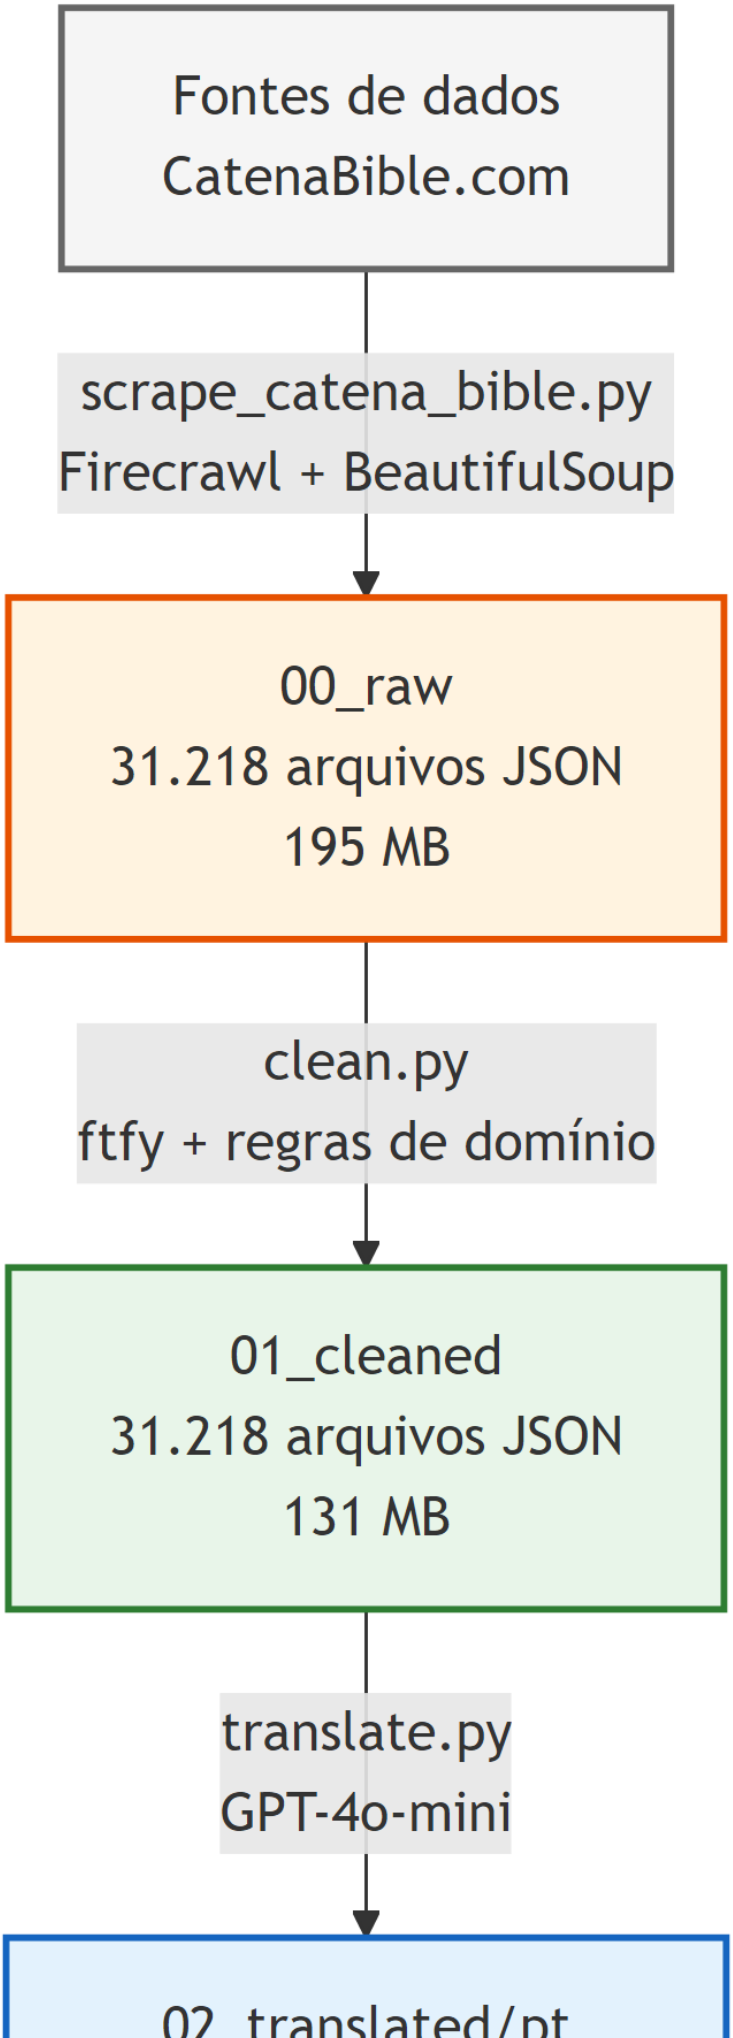
Fontes de dados
CatenaBible.com
scrape_catena_bible.py
Firecrawl + BeautifulSoup
00_raw
31.218 arquivos JSON
195 MB
clean.py
ftfy + regras de domínio
01_cleaned
31.218 arquivos JSON
131 MB
translate.py
GPT-4o-mini
02_translated/pt

2.3 Etapa 0: extração (*web scraping*)

A extração utiliza uma abordagem híbrida combinando dois motores (Figura 2):

- **Firecrawl**: navegação e extração de conteúdo completo, incluindo conteúdo de links secundários ("Go to Commentary")
- **BeautifulSoup**: *parsing* estruturado do HTML para identificar autor, período e conteúdo de cada comentário

O script implementa deduplicação por hash (primeiros 500 caracteres + URL) para evitar duplicatas entre os dois motores, e *checkpointing* por capítulo para permitir retomada em caso de interrupção. O resultado é um arquivo JSON por versículo contendo todos os comentários disponíveis.

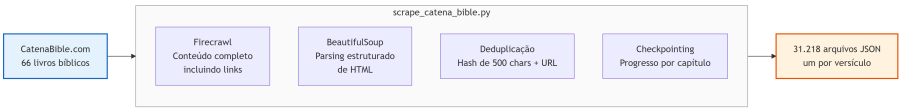

Figura 2: Arquitetura do *web scraping* híbrido
Fonte: Resultados originais da pesquisa

2.4 Etapa 1: limpeza de dados

A limpeza é a etapa mais crítica do pipeline. Utiliza a biblioteca `ftfy` (Speer, 2019) como motor principal para correção de problemas de codificação, combinada com regras de domínio específicas (Figura 3).

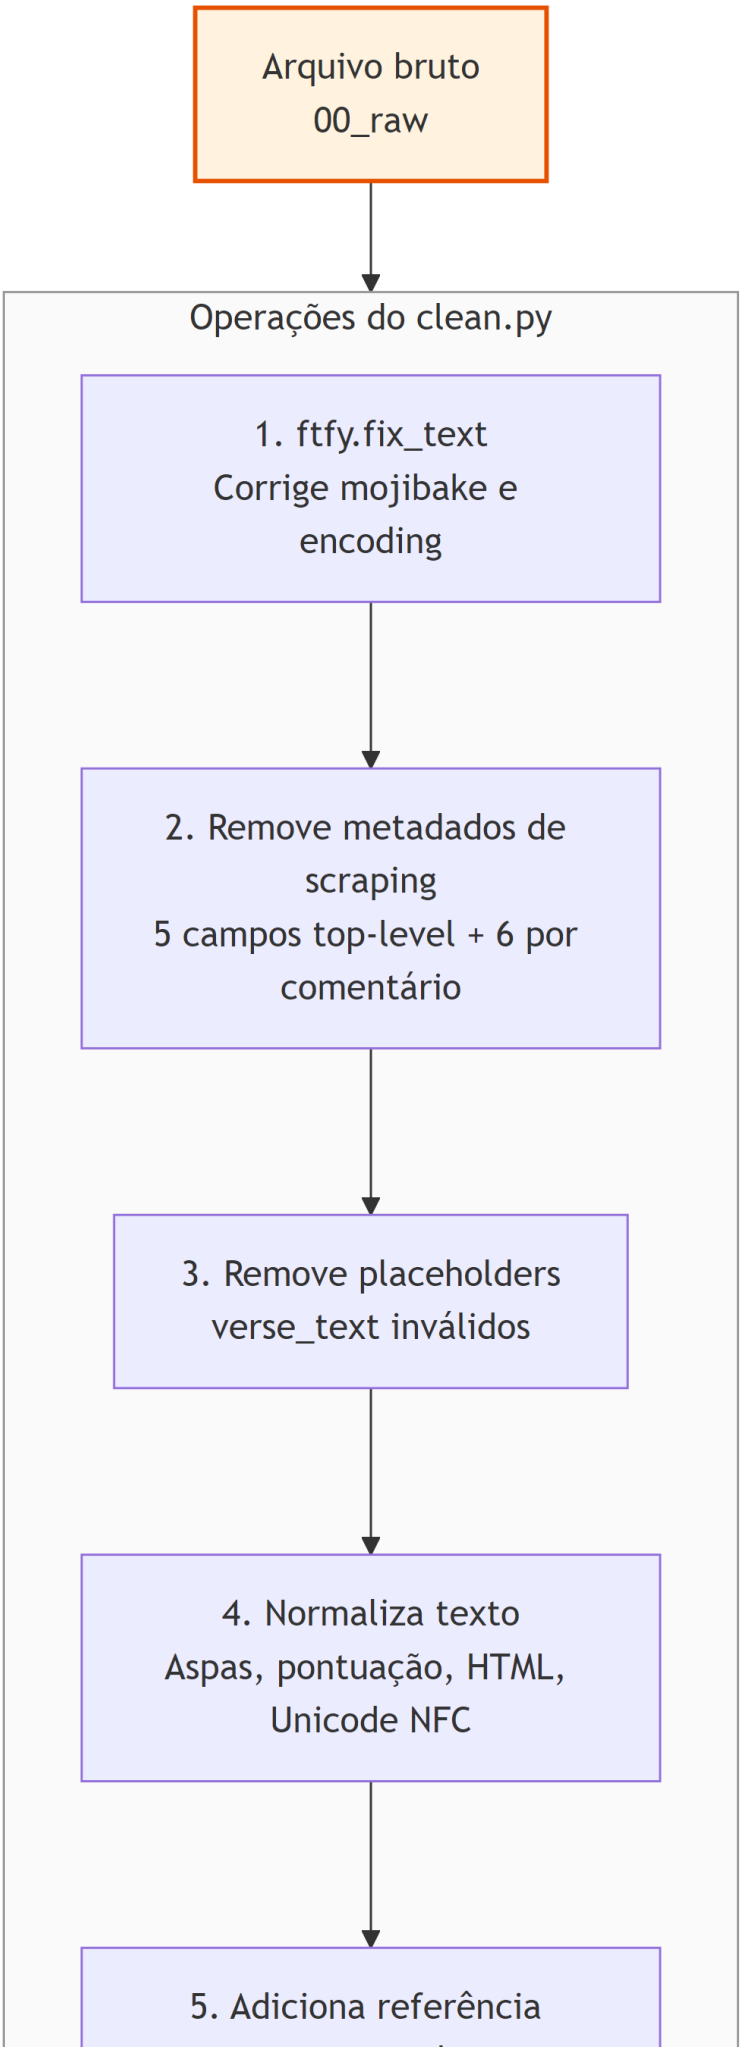
Arquivo bruto
00_raw
Operações do clean.py
1. ftfy.fix_text
Corrige mojibake e encoding
2. Remove metadados de scraping
5 campos top-level + 6 por comentário
3. Remove placeholders verse_text inválidos
4. Normaliza texto
Aspas, pontuação, HTML, Unicode NFC
5. Adiciona referência

A biblioteca `ftfy` detecta e corrige automaticamente *mojibake* — texto que foi codificado em UTF-8 mas decodificado incorretamente como Latin-1 ou CP-1252. Além disso, normaliza entidades HTML residuais, ligações tipográficas e caracteres de largura total.

As regras de domínio adicionais incluem:

1. Remoção de 5 campos de metadados de *scraping* do nível superior (`scraped_with`, `extraction_date`, `source_url`, `full_content_fetched`, `methodology`)
2. Remoção de 6 campos por comentário (`commentary_number`, `reading_time`, `source_url`, `full_content_url`, `content_type`, `extraction_method`)
3. Remoção de *placeholders* no campo `verse_text` (padrão "Verse text for {REF}")
4. Correção de aspas duplicadas, pontuação inicial órfã e *backslashes* residuais
5. Remoção de tags HTML remanescentes
6. Adição de campos de referência normalizados (`book`, `chapter`, `verse`), parseados do nome do arquivo
7. Normalização Unicode para forma NFC

O resultado é um JSON enxuto contendo apenas os campos relevantes para pesquisa: referência bíblica, status, contagem e lista de comentários (autor, período, conteúdo).

2.5 Etapa 2: tradução automática

A tradução do inglês para o português brasileiro utiliza o modelo GPT-4o-mini da OpenAI. O script suporta múltiplos idiomas por *design*: o parâmetro `-lang` define o idioma alvo, permitindo que o pipeline seja reutilizado para outros idiomas sem modificação.

Os arquivos traduzidos contêm apenas os campos essenciais: `verse_reference` e uma lista de comentários com `author`, `period` e `content_pt`. Metadados de tradução (modelo, data) são armazenados em arquivo separado (`translation_metadata.json`).

2.6 Etapa 3: enriquecimento por IA

O enriquecimento adiciona análise estruturada a cada comentário traduzido, utilizando GPT-4o-mini com um *system prompt* especializado em teologia patrística. Para cada comentário, quatro campos são gerados:

- `ai_summary`: resumo em uma frase, resumo expandido e pontos-chave
- `argumentative_structure`: tese, argumentos, objeções e conclusão
- `theological_analysis`: doutrinas, tradições (Alexandrina, Antioquena, Latina), método teológico e controvérsias
- `spiritual_insight`: tema central e reflexão prática

Esta etapa é executada seletivamente, dado o custo superior por arquivo ($0,01 vs $0,001 da tradução).

2.7 Validação e ferramentas auxiliares

O pipeline inclui três scripts de validação:

- `validate_schema.py`: valida cada arquivo contra o esquema esperado, identificando campos ausentes, conteúdos vazios e inconsistências de contagem
- `gap_audit.py`: compara duas camadas para detectar arquivos ausentes
- `generate_manifest.py`: gera inventário completo com contagem por livro, número de comentários e anomalias

3 Resultados e discussão

3.1 Escala do corpus

O corpus resultante contém 31.218 arquivos de versículos cobrindo os dois testamentos da Bíblia e livros deuterocanônicos (Tabela 1).

Tabela 1: Estatísticas gerais do corpus

Métrica	Valor
Total de arquivos de versículo	31.218
Comentários individuais	55.925
Versículos com comentários	22.537
Versículos sem comentários	8.681
Livros bíblicos cobertos	66
Autores únicos	100+
Período temporal	AD 100 – 1700

Fonte: Resultados originais da pesquisa

A Tabela 2 apresenta a distribuição dos arquivos por categoria bíblica. Os livros históricos do Antigo Testamento representam a maior concentração de comentários (6.851 arquivos), seguidos pelo Pentateuco (5.851) e pela literatura sapiencial (4.785).

Tabela 2: Distribuição dos arquivos por categoria bíblica

Categoria	Testamento	Arquivos
Livros Históricos	AT	6.851
Pentateuco	AT	5.851
Literatura Sapiencial	AT	4.785
Profetas Maiores	AT	4.544
Profetas Menores	AT	1.122
Deuterocanônicos	AT	167
Evangelhos	NT	3.779
Epístolas Paulinas	NT	2.110
Atos dos Apóstolos	NT	1.007
Epístolas Gerais	NT	734
Apocalipse	NT	404
Total		**31.354**

Fonte: Resultados originais da pesquisa

Os cinco autores mais frequentes no corpus são George Leo Haydock (AD 1849), João Crisóstomo (AD 407), Agostinho de Hipona (AD 430), Gregório Magno (AD 604) e Tertuliano de Cartago (AD 220), abrangendo tanto a tradição oriental quanto a ocidental.

3.2 Resultados da limpeza

A execução do script de limpeza sobre o corpus completo produziu os resultados apresentados na Tabela 3.

Tabela 3: Resultados da execução do `clean.py` sobre o corpus completo

Métrica	Valor
Arquivos processados	31.218
Correções de codificação (ftfy)	14.906
Campos de metadados removidos	156.090
Comentários removidos (conteúdo vazio)	1
Redução de tamanho	33% (195 MB $\rightarrow$ 131 MB)
Erros de processamento	0
Tempo de execução	119 segundos

Fonte: Resultados originais da pesquisa

A biblioteca `ftfy` corrigiu 14.906 problemas de codificação automaticamente, sem falsos positivos. A verificação em uma amostra de 1.000 arquivos confirmou zero perda de conteúdo: todos os 1.753 comentários da amostra foram preservados integralmente após a limpeza, com 253 normalizações de texto (correções de codificação) e nenhum caso de truncamento.

A remoção de 156.090 campos de metadados de *scraping* resultou em uma redução de 33% no tamanho total do corpus, produzindo arquivos JSON enxutos contendo apenas os campos relevantes para pesquisa.

3.3 Estrutura dos dados resultantes

O formato final de cada arquivo na camada limpa (01_cleaned) contém a seguinte estrutura:

```
{
  "verse_reference": "ACTS 1:1",
  "book": "acts",
  "chapter": 1,
  "verse": 1,
  "commentary_status": "available",
  "total_commentaries": 12,
  "commentaries": [
    {
      "author": "Bede",
      "period": "AD735",
      "content": "primeiro discurso: Ou seja, ..."
    }
  ]
}
```

3.4 Garantias do pipeline

O pipeline oferece três garantias fundamentais:

1. **Imutabilidade**: a camada 00_raw nunca é modificada após a extração, servindo como arquivo histórico. Checksums SHA-256 de 100 arquivos amostrados são armazenados em `PROVENANCE.json`
2. **Idempotência**: o script de limpeza produz a mesma saída para a mesma entrada, permitindo regeneração a qualquer momento
3. **Incrementalidade**: os scripts de tradução e enriquecimento detectam arquivos já processados e os ignoram, permitindo execução incremental sem reprocessamento

4 Conclusão

O pipeline proposto demonstrou ser capaz de organizar um corpus histórico de grande escala de forma reprodutível e rastreável.

A utilização da biblioteca `ftfy` para limpeza de codificação mostrou-se eficaz, corrigindo 14.906 problemas automaticamente sem falsos positivos e sem perda de conteúdo.

A separação explícita entre tradução e enriquecimento permite otimização de custos, com a possibilidade de traduzir o corpus inteiro a baixo custo e enriquecer seletivamente.

A organização por idioma (`02_translated/pt/`) torna o pipeline multilíngue por *design*.

O dataset completo, incluindo scripts, documentação e dados, está disponível publicamente em `https://github.com/neuu-org/bible-commentaries-dataset` sob licença CC BY 4.0.

Referências

Manning, C.D.; Raghavan, P.; Schütze, H. 2008. Introduction to Information Retrieval. 1ed. Cambridge University Press, Cambridge, UK.

OpenAI. 2024. GPT-4o mini: advancing cost-efficient intelligence. Disponível em: https://openai.com/index 4o-mini-advancing-cost-efficient-intelligence. Acesso em: 14 mar. 2026.

Richardson, L. 2023. Beautiful Soup documentation. Disponível em: https://www.crummy.com/software/Be Acesso em: 14 mar. 2026.

Speer, R. 2019. ftfy: fixes text for you. Disponível em: https://github.com/rspeer/python-ftfy. Acesso em: 14 mar. 2026.